乳腺癌诊断二分类课程实验报告

基于 scikit-learn 内置 Breast Cancer Wisconsin Diagnostic 数据集

实验内容涵盖数据划分、标准化、传统模型对比、分类指标统计、混淆矩阵、ROC/AUC 分析以及自动化 PDF 报告生成。

一、实验目的

本实验以乳腺癌诊断任务为背景，构建一个可复现的二分类机器学习流程。目标是比较多种传统分类模型在相同训练/测试集与标准化条件下的表现，并形成规范化实验报告。

二、数据集与实验设置

项目	内容
数据集名称	Breast Cancer Wisconsin Diagnostic
数据来源	sklearn.datasets.load_breast_cancer
样本数	569
特征数	30
标签定义	0 = Benign, 1 = Malignant
训练集 / 测试集	455 / 114
随机种子	42
标准化方式	StandardScaler fitted on the training split only

数据集中共包含 569 个样本、30 个数值特征。其中良性样本 357 个，恶性样本 212 个。实验采用固定随机种子 42，测试集比例为 20%。

三、模型与评价指标

实验比较 Logistic Regression、Support Vector Machine、K-Nearest Neighbors 与 Random Forest 四种传统模型。评价指标包括 Accuracy、Precision、Recall、F1-score、混淆矩阵以及 ROC/AUC。其中 Precision、Recall、F1-score 均以恶性样本（Malignant）作为正类进行计算。

四、结果对比

Model	Accuracy	Precision	Recall	F1	AUC
Support Vector Machine	0.9737	1.0000	0.9286	0.9630	0.9947
Random Forest	0.9737	1.0000	0.9286	0.9630	0.9944
Logistic Regression	0.9649	0.9750	0.9286	0.9512	0.9960
K-Nearest Neighbors	0.9561	0.9744	0.9048	0.9383	0.9825

按照 F1-score、AUC、Accuracy 的综合排序，本次实验表现最佳的模型为 Support Vector Machine。其测试集 Accuracy 为 0.9737，Precision 为 1.0000，Recall 为 0.9286，F1 为 0.9630，AUC 为 0.9947。

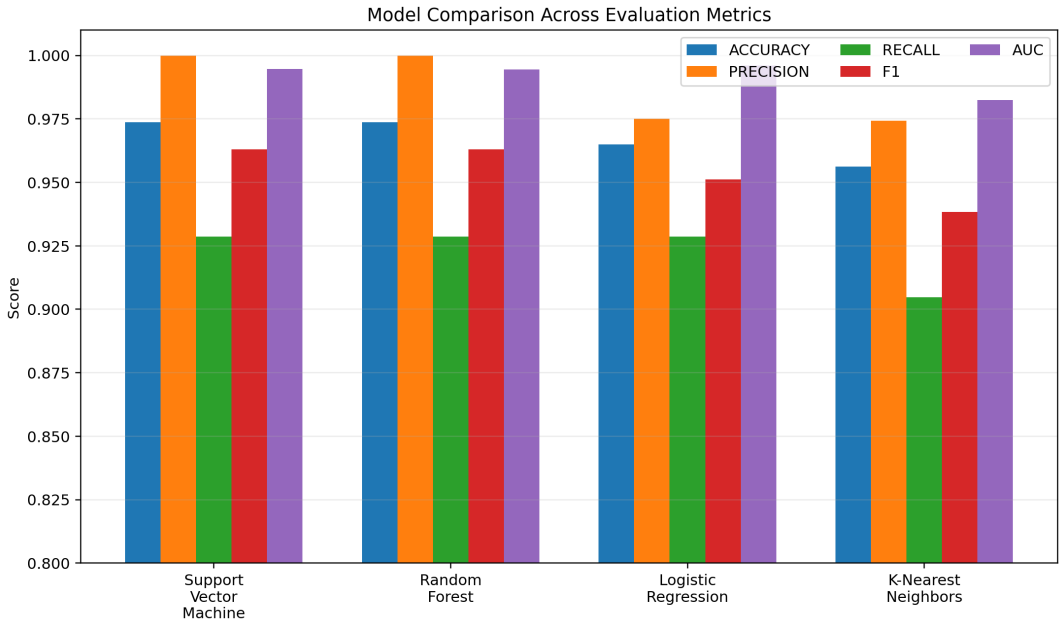

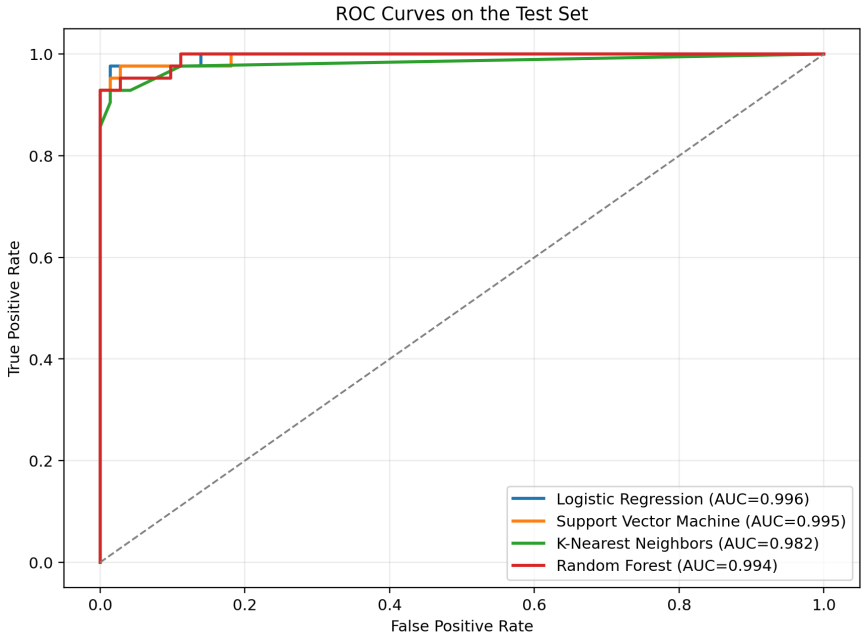

五、混淆矩阵分析

下图展示各模型在测试集上的混淆矩阵。主对角线越突出，说明模型正确分类的样本越多；对恶性样本的漏判数量越少，通常意味着模型在实际医学筛查场景中更具参考价值。

Logistic Regression

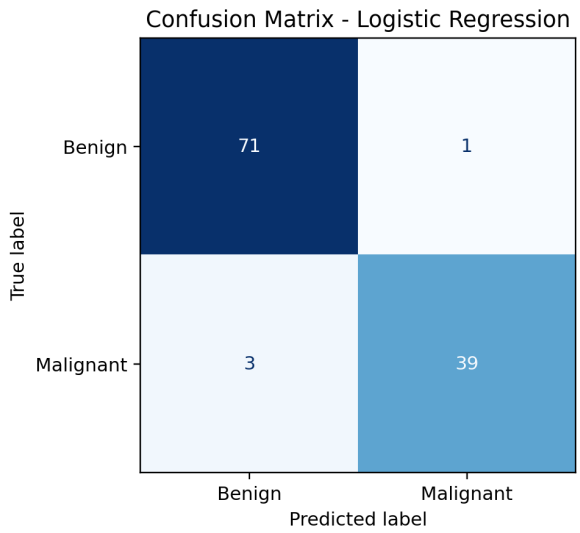

Support Vector Machine

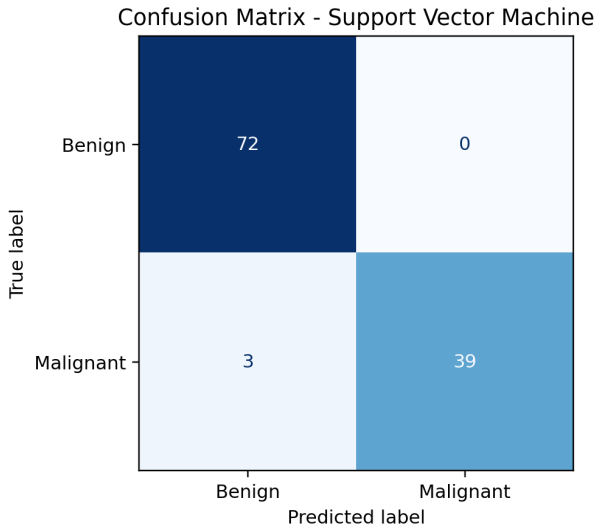

K-Nearest Neighbors

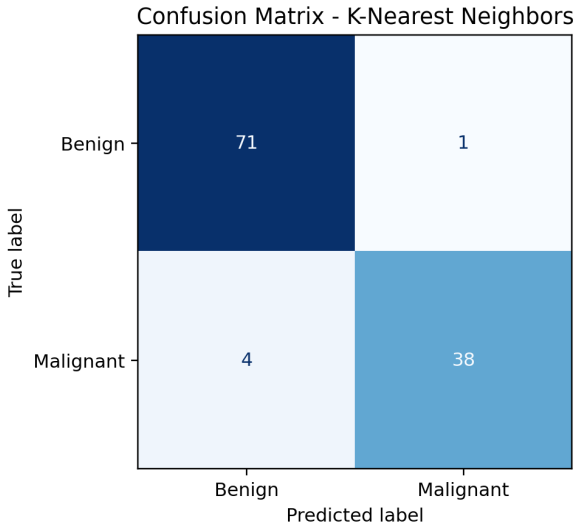

Random Forest

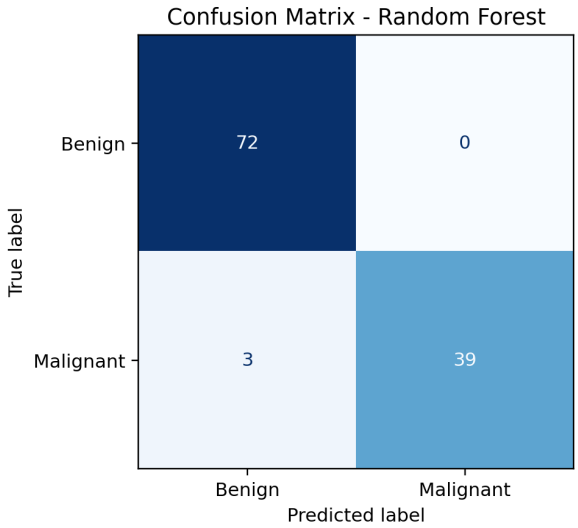

六、实验结论

1. 在相同的数据划分与标准化条件下，不同传统模型在该数据集上均取得了较高的分类性能，说明 Breast Cancer Wisconsin Diagnostic 数据集具有较好的可分性。

2. Support Vector Machine 在本次实验中的综合指标最优，尤其在恶性样本识别方面取得了较平衡的 Precision 与 Recall，因此更适合作为本次课程实验的推荐模型。

3. 自动化实验脚本能够一键完成训练、评估、绘图和 PDF 报告生成，适合用于课程提交、结果复现与后续扩展。

附注：图表、指标表与 PDF 均由程序自动落盘，便于在课程作业中直接引用。