机器学习课程实验报告

实验题目：基于 Breast Cancer Wisconsin 数据集的乳腺癌分类对比实验

生成时间：2026-03-31 17:02:36

报告类型：自动生成课程风格实验报告

数据集	Breast Cancer Wisconsin Diagnostic
样本数	569
特征数	30
类别分布	恶性 212，良性 357
实验模型	Logistic Regression, SVM, Random Forest, KNN
数据处理	训练/测试划分 + 基于训练集拟合的标准化

一、实验目标与方法

本实验基于 scikit-learn 自带的乳腺癌诊断数据集，完成一个从数据加载、训练/测试划分、标准化、模型训练、性能评估，到图表与 PDF
报告自动生成的完整流程。为了便于医学场景解释，实验将“恶性”定义为正类。

建模阶段比较了 Logistic Regression、SVM（RBF 核）、Random Forest 和 KNN
四类传统机器学习方法。其中涉及距离或线性决策边界的模型均通过 Pipeline 在训练集上拟合 StandardScaler，再应用到测试集，从而避免测试集信息泄露。

二、实验结果总览

模型	Train Acc	Accuracy	Precision	Recall	F1	AUC
Logistic Regression	0.9890	0.9737	0.9756	0.9524	0.9639	0.9960
SVM (RBF Kernel)	0.9868	0.9737	1.0000	0.9286	0.9630	0.9947
Random Forest	1.0000	0.9737	1.0000	0.9286	0.9630	0.9944
KNN	0.9714	0.9561	0.9744	0.9048	0.9383	0.9825

综合 F1、Accuracy 与 AUC 指标，最佳模型为 Logistic Regression。其测试集 Accuracy=0.9737，Recall=0.9524，AUC=0.9960。

图 1 模型指标对比

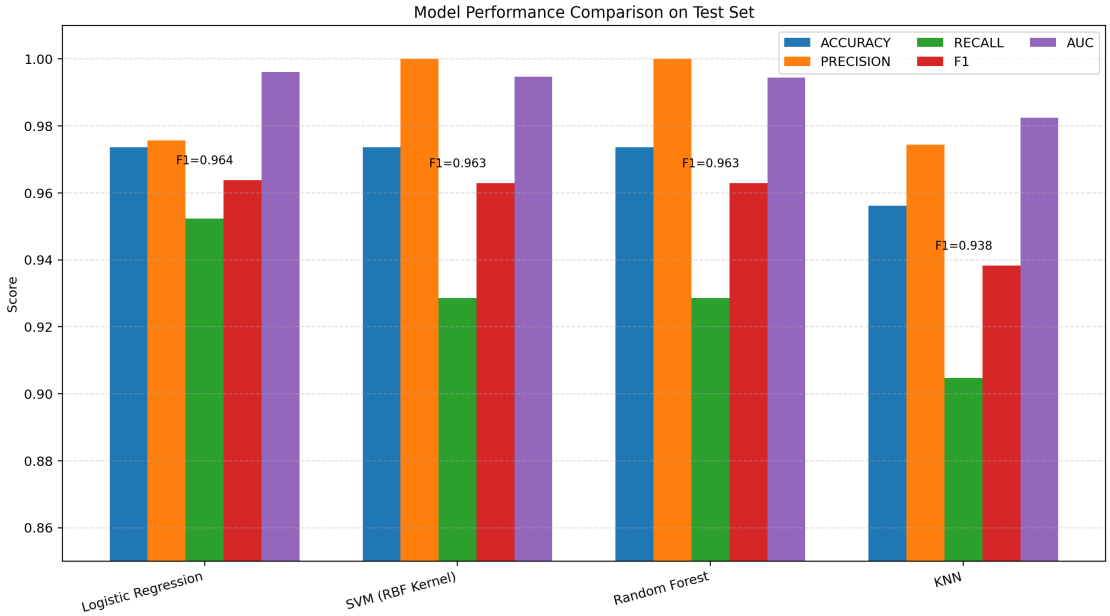
Model Performance Comparison on Test Set
ACCURACY
PRECISION
RECALL
F1
AUC
Score
1.00
0.98
0.96
0.94
0.92
0.90
0.88
0.86
F1=0.964
F1=0.963
F1=0.963
F1=0.938
Logistic Regression
SVM (RBF Kernel)
Random Forest
KNN

图 2 ROC 曲线

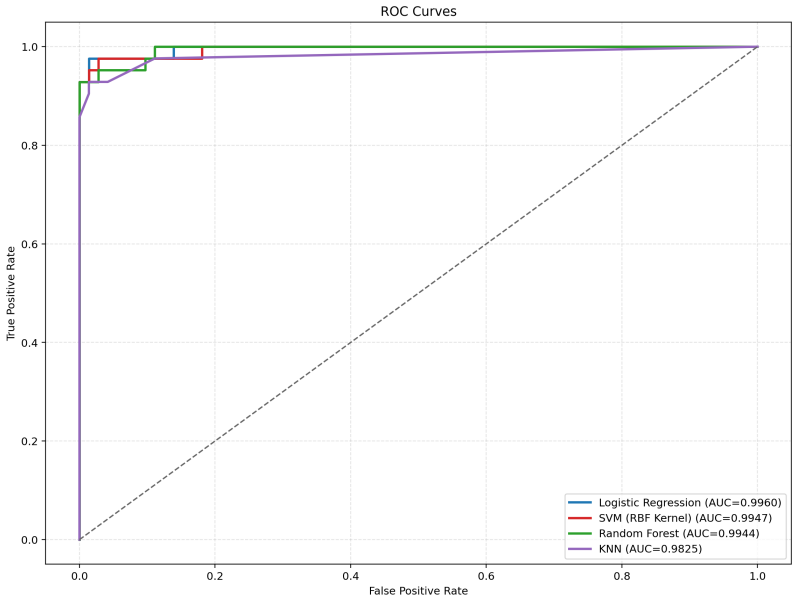
ROC Curves
True Positive Rate
False Positive Rate
0.0
0.2
0.4
0.6
0.8
1.0
Logistic Regression (AUC=0.9960)
SVM (RBF Kernel) (AUC=0.9947)
Random Forest (AUC=0.9944)
KNN (AUC=0.9825)

三、混淆矩阵与特征分析

混淆矩阵按照“恶性、良性”的顺序展示真实标签与预测标签。从图中可以直观看到不同模型在恶性样本识别上的错分情况。

图 3 不同模型的混淆矩阵

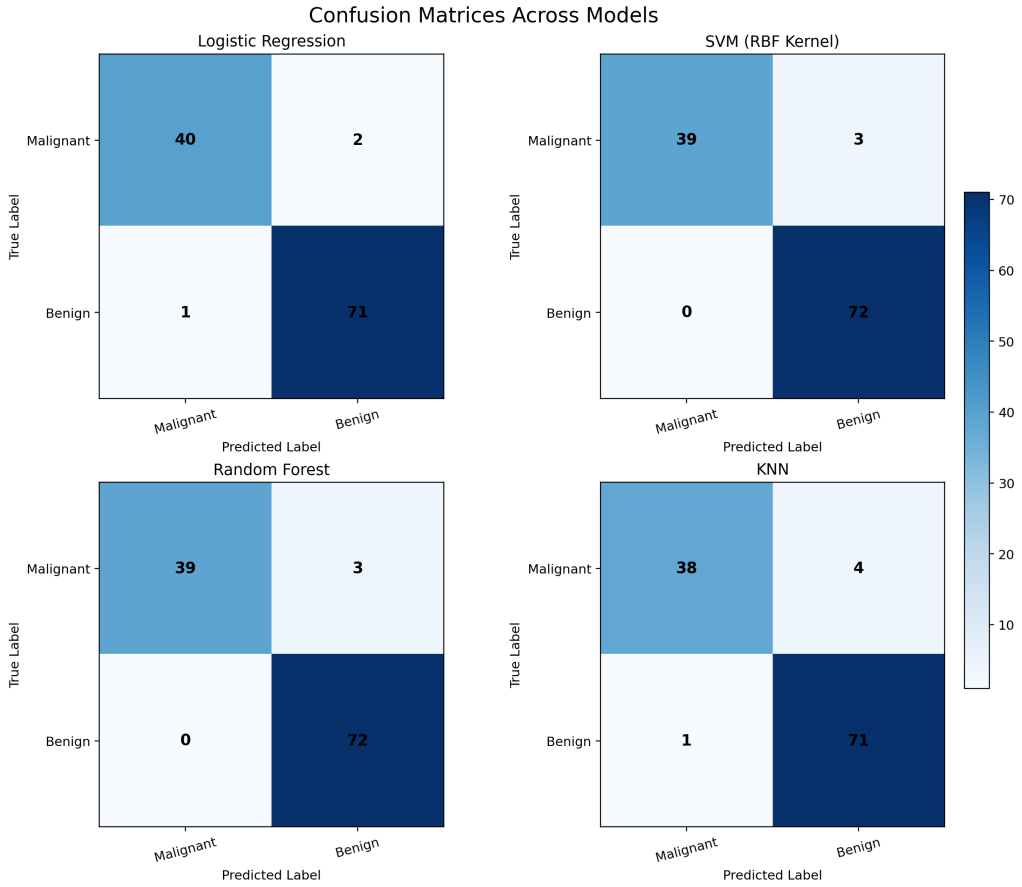

为了补充解释性，本实验额外输出了 Random Forest
的特征重要性排序图。可见若干半径、周长、面积和凹陷相关特征对分类决策影响更大。

图 4 Random Forest 特征重要性

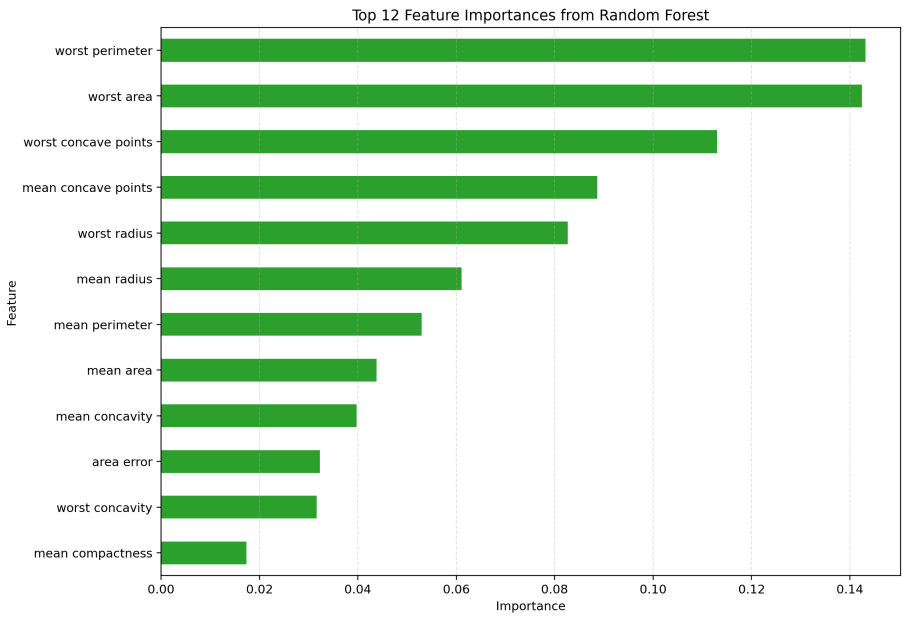

四、关键结论

1. Best overall model: Logistic Regression, with accuracy=0.9737, precision=0.9756, recall=0.9524, f1=0.9639, auc=0.9960.

2. Compared with the runner-up SVM (RBF Kernel), the best model improves F1 score by 0.0009.

3. The data split is stratified and feature scaling is applied within the training pipeline, preventing test-set leakage.

4. 从训练准确率与测试准确率的对比来看，Random Forest 的训练集拟合程度最高，但并不一定带来最优的泛化表现；对于本数据集，经过标准化后的边界型模型表现更稳健。

五、实验结论与可扩展方向

本实验已经完成课程作业要求的完整闭环：内置数据集加载、预处理、多模型对比、指标保存、图表输出、最佳模型总结以及 PDF 报告自动导出。后续可继续扩展交叉验证、超参数搜索、特征选择与模型解释方法，以形成更完整的实验平台。